

Probabilistic Language Modeling Smoothing

Dr. Saeedeh Momtazi



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)



آکادمی‌ها



Maximum Likelihood

<s> I saw the man </s>

$$P(S) = P(I) \cdot P(\text{saw}|I) \cdot P(\text{the}|\text{saw}) \cdot P(\text{man}|\text{the})$$

$$P(S) = \frac{\#(I)}{\#} \cdot \frac{\#(I \text{ saw})}{\#(I)} \cdot \frac{\#(\text{saw the})}{\#(\text{saw})} \cdot \frac{\#(\text{the man})}{\#(\text{the})}$$

$$P(S) = \frac{2}{13} \cdot \frac{1}{2} \cdot \frac{1}{1} \cdot \frac{1}{3}$$



boy	I	in	is	Man	saw	street	The	walked	working
1	2	1	1	1	1	1	3	1	1

[illegible]



Maximum Likelihood

<s> I saw the man in the street </s>

$$P(S) = P(I) \cdot P(\text{saw} | I) \cdot P(\text{the} | \text{saw}) \cdot P(\text{man} | \text{the}) \cdot P(\text{in} | \text{man}) \cdot P(\text{the} | \text{in}) \cdot P(\text{street} | \text{the})$$

$$P(S) = \frac{\#(I)}{\#} \cdot \frac{\#(I \text{ saw})}{\#(I)} \cdot \frac{\#(\text{saw the})}{\#(\text{saw})} \cdot \frac{\#(\text{the man})}{\#(\text{the})} \cdot \frac{\#(\text{man in})}{\#(\text{man})} \cdot \frac{\#(\text{in the})}{\#(\text{in})} \cdot \frac{\#(\text{the street})}{\#(\text{the})}$$

$$P(S) = \frac{2}{13} \cdot \frac{1}{2} \cdot \frac{1}{1} \cdot \frac{1}{3} \cdot \frac{0}{1} \cdot \frac{1}{1} \cdot \frac{1}{3}$$



- Giving a small probability to all as unseen n-grams



Laplace Smoothing

➤ Add one to all counts (Add-one)

[illegible]

[illegible]




The intuition of smoothing

➤ When we have sparse statistics:


$P(w \mid \text{denied the})$
3 allegations
2 reports
1 claims
1 request

7 total



➤ Steal probability mass to generalize better

$P(w \mid \text{denied the})$
2.5 allegations
1.5 reports
0.5 claims
0.5 request
2 other
7 total





Laplace Smoothing

➤ Add one to all counts (Add-one)

$$\Rightarrow P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} \Rightarrow P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + 1}{\#(w_{i-1}) + V}$$



➤ Interpolation and Back-off Smoothing

- ▶ Use a background probability

$$P(w_i|w_{i-1}) = \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})}$$

Back-off

$$P(w_i|w_{i-1}) = \begin{cases} \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} & \text{if } \#(w_{i-1}, w_i) > 0 \\ P_{BG} & \text{Otherwise} \end{cases}$$



➤ Interpolation and Back-off Smoothing

- ▶ Use a background probability

$$P(w_i|w_{i-1}) = \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})}$$

Interpolation

$$P(w_i|w_{i-1}) = \lambda_1 \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} + \lambda_2 P_{BG} \quad \sum \lambda = 1$$

Parameter
Tuning

Background
Probability



Background Probability

- Lower levels of n-gram can be used as background probability
- trigram → bigram
- bigram → unigram
- unigram → zerogram ($1/V$)



Background Probability

- Lower levels of n-gram can be used as background probability
- trigram → bigram
- bigram → unigram
- unigram → zerogram ($1/V$)

Back-off

$$P(w_i | w_{i-1}) = \begin{cases} \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} & \text{if } \#(w_{i-1}, w_i) > 0 \\ P_{BG} & \text{Otherwise} \end{cases}$$



Background Probability

Back-off

$$P(w_i | w_{i-1}) = \begin{cases} \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} & \text{if } \#(w_{i-1}, w_i) > 0 \\ P_{BG} & \text{Otherwise} \end{cases}$$

$$P(w_i) = \begin{cases} \frac{\#(w_i)}{N} & \text{if } \#(w_i) > 0 \\ 1/V & \text{Otherwise} \end{cases}$$



Background Probability

Interpolation

$$P(w_i|w_{i-1}) = \lambda_1 \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} + \lambda_2 P_{BG}$$

$$P(w_i) = \lambda_1 \frac{\#(w_i)}{N} + \lambda_2 \cdot (1/V)$$



Advanced Smoothing

- Bayesian Smoothing with Dirichlet Prior
- Absolute Discounting
- Kneser-Ney Smoothing
- Bayesian Smoothing based on Pitman-Yor Processes



Bayesian Smoothing with Dirichlet Prior

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + 1}{\#(w_{i-1}) + V}$$

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + k}{\#(w_{i-1}) + kV}$$

$$\mu = kv$$

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + \mu \left(\frac{1}{v}\right)}{\#(w_{i-1}) + \mu}$$

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + \mu P_{BG}}{\#(w_{i-1}) + \mu}$$



Absolute Discounting

$$P(w_i | w_{i-1}) = \begin{cases} \frac{\#(w_{i-1}, w_i)}{\#(w_{i-1})} & \text{if } \#(w_{i-1}, w_i) > 0 \\ P_{BG} & \text{Otherwise} \end{cases}$$

$$P(w_i | w_{i-1}) = \begin{cases} \frac{\#(w_{i-1}, w_i) - \delta}{\#(w_{i-1})} & \text{if } \#(w_{i-1}, w_i) > 0 \\ \alpha P_{BG} & \text{Otherwise} \end{cases}$$



Absolute Discounting

$$P(w_i|w_{i-1}) = \frac{\#(w_{i-1}, w_i) - \delta}{\#(w_{i-1})} + \alpha P_{BG}$$

$$\alpha = \frac{\delta}{\#(w_{i-1})} \cdot B$$

B : the number of times $\#(w_i, w_{i-1}) > 0$

(the number of times that we applied discounting)

$$P(w_i|w_{i-1}) = \frac{\max(\#(w_{i-1}, w_i) - \delta, 0)}{\#(w_{i-1})} + \alpha P_{BG}$$



Kneser-Ney Smoothing

➤ Estimation base on the lower-order n-gram

"I cannot see without my reading ... " → "Francisco"
"glasses"

➤ Observations:

- ▶ "Francisco" is more common than "glasses"
- ▶ But "Francisco" always follows "San"
- ▶ "Francisco" is not a novel continuation for a text

➤ Solution:

- ▶ Instead of $p(w)$: "How likely is w to appear in a text"
- ▶ $p_{\text{Continuation}}(w)$: "How likely is w to appear as a novel continuation"
- ▶ Count the number of words types that w appears after them

$$P_{\text{continuation}}(w) \propto |w_{i-1}: \#(w_{i-1}; w_i) > 0|$$



Kneser-Ney Smoothing

➤ How many times does w appear as a novel continuation

$$P_{\text{continuation}}(w) \propto |w_{i-1}: \#(w_{i-1}, w_i) > 0|$$

➤ Normalized by the total number of bigram types

$$P_{\text{continuation}}(w) = \frac{|w_{i-1}: \#(w_{i-1}, w_i) > 0|}{|(w_{j-1}, w_j): \#(w_{j-1}, w_j) > 0|}$$

➤ Alternatively: normalized by the number of words preceding all words

$$P_{\text{continuation}}(w) = \frac{|w_{i-1}: \#(w_{i-1}, w_i) > 0|}{\sum_{w'} |w'_{i-1}: \#(w'_{i-1}, w'_i) > 0|}$$



Kneser-Ney Smoothing

$$P(w_i|w_{i-1}) = \frac{\max(\#(w_{i-1}, w_i) - \delta, 0)}{\#(w_{i-1})} + \alpha P_{BG}$$

$$P(w_i|w_{i-1}) = \frac{\max(\#(w_{i-1}, w_i) - \delta, 0)}{\#(w_{i-1})} + \alpha P_{continuation}$$

$$\alpha = \frac{\delta}{\#(w_{i-1})} \cdot B$$

B : the number of times $\#(w_{i-1}, w_i) > 0$



Bayesian Smoothing based on Pitman-Yor Processes

➤ Improving the Dirichlet prior by using a discounting parameter deriving from absolute discounting method

➤ Dirichlet prior
$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) + \mu P_{BG}}{\#(w_{i-1}) + \mu}$$

➤ Absolute discounting
$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) - \delta + (\delta \cdot B) P_{BG}}{\#(w_{i-1})}$$

➤ Combined
$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) - \delta + (\mu + \delta \cdot B) P_{BG}}{\#(w_{i-1}) + \mu}$$



Bayesian Smoothing based on Pitman-Yor Processes

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) - \delta t + (\mu + \delta t.) P_{BG}}{\#(w_{i-1}) + \mu}$$

➤ t : discounting weight

➤ $t.$: total amount of applied discounting



Bayesian Smoothing based on Pitman-Yor Processes

- Using different discounting value for each word based on the frequency of that word

$$P(w_i | w_{i-1}) = \frac{\#(w_{i-1}, w_i) - \delta t + (\mu + \delta t.) P_{BG}}{\#(w_{i-1}) + \mu}$$

- t : discounting weight
- $t.$: total amount of applied discounting
- $t = 1 \rightarrow$ basic combined model
- $\mu = 0 \rightarrow$ absolute discounting method



Bayesian Smoothing based on Pitman-Yor Processes

- Calculating parameter t is the most important and computationally expensive part of the formula
- Idea for a near optimum estimation of t : Generating a power-law distribution in the language model, which is one of the statistical properties of word frequencies in natural language

$T=0$ if $\#(w_{i-1}, w_i) = 0$

$t = f(\#(w_{i-1}, w_i)) = (\#(w_{i-1}, w_i))^\delta$ if $\#(w_{i-1}, w_i) > 0$



▶ Chapter 3