

Persian Text Processing

Dr. Saeedeh Momtazi



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)



آکادمی هاه



➤ Challenges in Persian Text Processing



Character Encoding

➤ Mixing of Arabic and Persian characters

(ك vs ک | ي vs ی)

➤ Sorting Persian characters according to Arabic

الف، ب، ت، ث، ج، ح، خ، د، ذ، ر، ز، س، ش، ص، ض، ط، ظ، ع، غ
ف، ق، ل، م، ن، هـ، و، پ، چ، ژ، ک، گ، ی



- Using space as word boundary
- Multi-token unit problem due to the letters not joined to the next letter
(ا، د، ذ، ر، ز، ژ، و)
 - ▶ Causes ambiguity in word segmentation
('we in' ما در vs 'mother' مادر | 'and with' و با vs 'cholera' و با)
 - ▶ Number
('123 barrels' ۱۲۳ بشکه vs ۱۲۳ بشکه)

➤ Using the zero-width non-joiner space (ZWNJS)

➤ Multi-unit token problem

White-space	ZWNJS	Attached	Transliteration	Translation
می گوید	می گوید	میگوید	miguyad	says
هم کلاسی	هم کلاسی	همکلاسی	hamkelāsi	classmate
بی نیاز	بی نیاز	—	biniyāz	needless
پول ها	پول ها	پولها	pulhā	monies
خانه ای	خانه ای	—	xāne?i	a house
بزرگ تر	بزرگ تر	بزرگتر	bozorgtar	bigger
بزرگ ترین	بزرگ ترین	بزرگترین	bozorgtarin	biggest
بین المللی	بین المللی	—	beynolmelali	international
زبان شناسی	زبان شناسی	زبانشناسی	zabānšenāsi	linguistics
کتاب سرا	کتاب سرا	کتابسرا	ketābsarā	book-house
دانش آموز	دانش آموز	—	dānešāmuz	student
علاقه مند	علاقه مند	علاقمند	alāqemand	interested
تخم مرغ	تخم مرغ	—	toxmemorq	egg
به شیوه	به شیوه	بشیوه	bešiveye	like
سنگین وزن	سنگین وزن	—	sanginvazn	heavy
در غیر این صورت	در غیر این صورت	درغیراینصورت	darqeyre?insurat	otherwise
به محض این که	به محض این که	—	bemahze?inke	as soon as
صد و بیست و سه هزار	صد و بیست و سه هزار	—	sadobistosehezār	123000
این کار	این کار	اینکار	in kār	this work



➤ Language varieties

- ▶ Standard: اگر /?agar/ 'if'
- ▶ Super-standard: گر /gar/ 'if'
- ▶ Sub-standard: اگه /?age/ 'if'

➤ Coining a simple spelling for the existing complex word

(زنگ زدن /zang zadan/ 'call' vs زنگیدن /zangidan/ 'call')

➤ Spelling variation for Arabic words:

(حتا vs حتی /hattā/ 'even')

(حتمن vs حتماً /hatman/ 'certainly')



Homographs and Homonyms

➤ Writing no short vowels: کند

▶ /kond/ 'blunt'

▶ /kanad/ 'picking up'

▶ /konad/ 'doing'

▶ /kand/ 'picked up'

➤ No capitalization: آذر /āzar/

▶ the name of the 9th month in the Persian calendar

▶ girl's name

▶ fire



Borrowed Diacritic Characters from Arabic

➤ Tanvin:

جدا /jodā/ 'separate' vs جداً /jeddan/ 'really'

➤ Tašdid:

بنا / bannā/ 'bricklayer' vs بنا /banā/ 'building, base'

➤ Hamze:

رئيس /reʔis/ vs رئيس /reyis/ 'boss'

➤ Short Alef ا:

حتى /hattā/ 'even' vs حتى



Spelling Variations for Words

➤ Hamze

➤ Writing 'l' instead of 'ī'

امریکائی /ʔemrikāʔi/

امریکایی /ʔemrikāyi/

آمریکائی /āmrikāʔi/


آمریکایی /āmrikāyi/



Spelling Variations for Words

➤ Ezāfe

- ▶ With the intermediary morpheme 'ی' /y/ along with a white-space or ZWNJS at the end of the word, such as 'خانه‌ی' or 'خانه ی' /xāneye/ 'the house of'
- ▶ Writing ء instead of the intermediary morpheme 'ی' /y/ (خانهء /xāneye/ vs خانه ی /xāneye/ 'the house of')
- ▶ Without Ezāfe but pronounced: خانه




➤ No standard method to write foreign words

▶ اینترمدییت /intermediyet/

▶ اینترمڈیت /intermediyet/

▶ اینترمیدییت /intermidiyet/

▶ اینترمیدییت /intermidiyet/



Contracted Forms

- Phrasal/complex words
- Big challenge in syntactic parsing
 - ▶ چته /čete/ 'what is the matter with you?'
 - ▶ چیه /čiye/ 'what? | what is it?'
 - ▶ بچته /baččate/ 'Is it your child?'
 - ▶ کیست /kisti/ 'who are you?'
 - ▶ کو /ku/ 'where is it? | that he/she'
 - ▶ کز /kaz/ 'that from'
 - ▶ کزو /kazu/ 'that from he/she'



➤ Papers

▶ A study of corpus development for Persian

▶ M Ghayoomi, S Momtazi, M Bijankhan - International Journal on ALP, 2010

▶ Lessons from building a Persian written corpus: Peykare

▶ M Bijankhan, J Sheykhzadegan, M Bahrani, M Ghayoomi - Language resources and evaluation, 2011

▶ Corpus-based analysis for multi-token units in Persian

▶ M Sharifi Atashgah, M Bijankhan, INTERNATIONAL JOURNAL OF INFORMATION AND COMMUNICATION TECHNOLOGY RESEARCH, 2009